Monitor de “Temperatura emocional” en tiempo real

Josmar Brazón
Universidad de Buenos Aires
Buenos Aires
jkbathanasopulos@gmail.com

Martin Gonzalez
Universidad de Buenos Aires
Buenos Aires
mgonzalez738@gmail.com

Martín Andrés
Universidad de Buenos Aires
Buenos Aires
martinfernandoandres1996@gmail.com

Gastón Corti
Universidad de Buenos Aires
Buenos Aires
gaston.corti@gmail.com

Abstracto—Este trabajo presenta el diseño, entrenamiento y evaluación de un clasificador de emociones faciales basado en una Red Neuronal Convolucional (CNN) propia. El modelo fue entrenado sobre el dataset FER2013, que comprende imágenes de rostros etiquetadas en siete categorías emocionales: enojo, asco, miedo, felicidad, tristeza, sorpresa y neutral. Se aplicaron técnicas de data augmentation y un sampler balanceado para compensar el desbalance de clases minoritarias. El sistema fue extendido al dominio del video con detección de rostros mediante Haar Cascade (análisis de sentimiento promedio) y YOLOv8 (análisis temporal), permitiendo construir una curva de temperatura emocional a lo largo del tiempo mediante suavizado por rolling average de cinco frames.

Palabras claves—reconocimiento de emociones, red neuronal convolucional, FER2013, YOLOv8, análisis temporal, detección facial, visión por computadora

I. Introducción

Las emociones son el sustrato invisible de toda interacción humana. Detrás de cada conversación, negociación, clase o entrevista existe un flujo continuo de señales afectivas que los interlocutores leen —consciente o inconscientemente— para ajustar su comportamiento. Sin embargo, en un mundo donde una proporción creciente de esas interacciones ocurre a través de plataformas digitales, ese canal de lectura emocional se ve degradado: las videollamadas comprimen, pixelan y recortan aquello que en persona sería inmediato. La pregunta que motiva este trabajo es si la computación puede recuperar, y eventualmente potenciar, esa capacidad perdida.

El reconocimiento automático de expresiones faciales es hoy una de las líneas más activas dentro de la visión por computadora, y sus aplicaciones abarcan dominios donde la dimensión afectiva es estratégicamente relevante: los equipos de recursos humanos podrían analizar la coherencia emocional de un candidato durante una entrevista grabada; los equipos de ventas podrían identificar con precisión en qué momento de una demostración de producto un cliente pierde interés o manifiesta entusiasmo; los docentes de plataformas de educación online podrían acceder a una medición objetiva del nivel de atención o confusión de sus alumnos durante una clase virtual. En todos estos casos, el valor no reside en un instante aislado, sino en la evolución emocional a lo largo del tiempo.

El presente trabajo propone y evalúa un sistema integral de reconocimiento de emociones faciales construido en etapas progresivas. En su núcleo, una Red Neuronal Convolucional de arquitectura propia fue entrenada sobre el dataset FER2013 —más de 35.000 imágenes de rostros en escala de grises, etiquetadas en siete categorías emocionales: enojo, asco, miedo, felicidad, tristeza, sorpresa y neutral—. Esta elección metodológica responde a un objetivo explícito: comprender en profundidad cada decisión del pipeline de entrenamiento, desde el diseño de los bloques convolucionales hasta la gestión del severo desbalance de clases propio del dataset, abordado mediante muestreo ponderado y técnicas de aumento de datos.

Una dimensión crítica de cualquier sistema de aprendizaje automático es su capacidad de generalizar más allá de los datos con los que fue entrenado. Para evaluar esta propiedad, se realizó una validación cruzada utilizando el dataset CK+ (Extended Cohn-Kanade), un corpus de naturaleza fundamentalmente distinta: compuesto por secuencias de video en las que los sujetos transitan desde una expresión neutra hacia el pico de una emoción específica. Esta característica permitió, además, construir ejemplos de prueba particularmente controlados —tomando el primer frame de cada secuencia como estado de seriedad y el último como la emoción objetivo—, lo que convierte a CK+ en un banco de pruebas ideal para medir la robustez del modelo en condiciones no vistas. Adicionalmente, los resultados de la CNN propia fueron contrastados con los de un Vision Transformer preentrenado, lo que permitió una comparación directa entre enfoques convolucionales clásicos y arquitecturas basadas en atención, revelando fortalezas y debilidades de cada paradigma frente a clases emocionales específicas.

Finalmente, el trabajo extiende el clasificador al dominio del video para construir lo que denominamos una curva de temperatura emocional: una representación continua del estado afectivo de un sujeto a lo largo del tiempo. El sistema incorpora detección de rostros con YOLOv8 —más robusto que el clásico Haar Cascade ante variaciones de pose e iluminación— y un mecanismo de suavizado por promedio móvil que atenúa el ruido inter-fotograma. El resultado es un prototipo funcional que, dado un video de entrada, produce una visualización completa de la dinámica emocional de la sesión: la prueba de concepto de una herramienta con potencial de aplicación real en cualquier contexto donde el flujo emocional captado por una cámara sea información estratégicamente valiosa.

II. Dataset y Preprocesamiento

A. *Dataset de Entrenamiento: FER2013*

El modelo fue entrenado sobre FER2013, un dataset de acceso público compuesto por imágenes de rostros en escala

de grises de 48×48 píxeles, distribuidas en siete categorías emocionales: enojo, asco, miedo, felicidad, tristeza, sorpresa y neutral. El conjunto de entrenamiento consta de aproximadamente 28.709 imágenes y el de validación de 3.589. Una característica determinante de este dataset es su marcado desbalance de clases: las categorías *felicidad* y *neutral* concentran la mayor proporción de muestras, mientras que *asco* y *miedo* presentan una representación notablemente inferior. Este desbalance fue abordado mediante un muestreo ponderado durante el entrenamiento, asignando a cada muestra un peso inversamente proporcional a la frecuencia de su clase.

B. Dataset de Validación Cruzada: CK+

El modelo fue entrenado y evaluado inicialmente sobre FER2013 (Sección IV.B). Sin embargo, evaluar un modelo exclusivamente sobre datos del mismo dominio en el que fue entrenado no garantiza que sus resultados sean generalizables. Para abordar esta limitación, se incorporó un segundo dataset de naturaleza fundamentalmente distinta como banco de pruebas externo: el Extended Cohn-Kanade (CK+).

CK+ está compuesto por secuencias de video grabadas en condiciones controladas de laboratorio, en las que sujetos transitan de manera deliberada desde una expresión neutra hacia el pico de una emoción determinada. Para la construcción del conjunto de validación, se tomó el primer fotograma de cada secuencia como representante de la clase seriedad y el último fotograma como representante de la emoción correspondiente.

Es relevante notar que CK+ define originalmente ocho categorías emocionales, incluyendo desprecio (contempt), una clase inexistente en FER2013. Para garantizar la comparabilidad directa entre ambos datasets, esta clase fue excluida. Las siete clases restantes fueron mapeadas manualmente a las categorías equivalentes de FER2013, resultando en la siguiente distribución: alegría (69), disgusto (59), enojo (45), miedo (25), seriedad (309), sorpresa (83) y tristeza (28).

El dataset resultante comprende 618 imágenes con una fuerte predominancia de la clase seriedad (309 muestras), derivada de la naturaleza misma de las secuencias. Dado que ninguna imagen de CK+ formó parte del entrenamiento, este conjunto constituye una evaluación genuina de la robustez del modelo frente a datos no vistos, complementando la evaluación interna sobre FER2013 con una validación cruzada sobre un dominio externo.

C. Preprocesamiento y Aumento de Datos

Para el conjunto de entrenamiento se aplicó un pipeline de aumento de datos que introduce variaciones controladas sobre cada imagen: volteo horizontal aleatorio, rotación de hasta ±15°, variaciones de brillo y contraste, y recorte aleatorio con relleno de 4 píxeles. Todas las imágenes fueron convertidas a escala de grises, redimensionadas a 48×48 píxeles y normalizadas con media y desviación estándar de 0.5. Para el conjunto de validación se aplicó únicamente la normalización, sin ninguna transformación aleatoria, garantizando condiciones de evaluación reproducibles.

III. Arquitectura de los modelos

A. Diseño de los Bloques Convolucionales

La unidad fundamental de la CNN desarrollada es un bloque convolucional compuesto por dos capas Conv2d sucesivas, cada una seguida de Batch Normalization y activación ReLU. El uso de dos convoluciones por bloque —en lugar de una— demostró empíricamente mejorar las métricas de precisión y recall, especialmente en las clases minoritarias. El bias fue desactivado en todas las capas convolucionales, dado que Batch Normalization lo hace redundante. Se utilizó padding de tipo *same* para preservar las dimensiones espaciales dentro de cada bloque.

B. Arquitectura CNN Completa

La red se organiza en tres bloques consecutivos que duplican progresivamente el número de canales de salida: 32, 64 y 128 respectivamente. Cada bloque incorpora, al final, una operación de max pooling que reduce la resolución espacial a la mitad. Tras el tercer bloque, un módulo de Global Average Pooling (GAP) colapsa cada mapa de características en un único valor escalar, produciendo un vector de 128 dimensiones independiente de la resolución de entrada. A este vector se le aplica Dropout con probabilidad 0.4 como mecanismo de regularización, y finalmente una capa totalmente conectada lo proyecta hacia las siete clases emocionales de salida. La función de pérdida utilizada es Cross-Entropy Loss y el optimizador es Adam con un scheduler de tasa de aprendizaje adaptativa que reduce el LR cuando la pérdida de validación deja de mejorar.

C. Vision Transformer como Modelo de Referencia

Con el objetivo de contextualizar el rendimiento de la CNN propia frente al estado del arte, se evaluó un Vision Transformer (ViT) preentrenado sobre el mismo conjunto de validación cruzada CK+. El modelo seleccionado fue dima806/facial_emotions_image_detection, disponible en Hugging Face, basado en la arquitectura ViT-base-patch16-224 preentrenada sobre ImageNet-21k y ajustada (fine-tuned) específicamente para clasificación de emociones faciales. Los ViT dividen la imagen en parches de tamaño fijo (16×16 píxeles), los proyectan a un espacio de embeddings y aplican mecanismos de auto-atención para capturar relaciones globales entre regiones de la imagen, prescindiendo del sesgo inductivo local propio de las convoluciones. En el contexto del reconocimiento de expresiones faciales, esto representa una ventaja teórica para capturar configuraciones musculares distribuidas a lo largo del rostro. Cabe destacar que este modelo opera sobre imágenes de 224×224 píxeles en RGB —aproximadamente 22 veces más píxeles y tres veces más canales que los 48×48 en escala de grises de la CNN propia—, lo que implica una diferencia sustancial en la cantidad de información disponible para la clasificación.

D. Comparación entre Enfoques

La comparación de resultados se presenta en la Sección IV.

IV. Entrenamiento y Evaluación

A. Protocolo de Entrenamiento

El entrenamiento se realizó sobre el conjunto de entrenamiento de FER2013 con batch size de 64, utilizando

el optimizador Adam y la función de pérdida Cross-Entropy Loss. Para gestionar la convergencia se empleó un scheduler *ReduceLROnPlateau*: cuando la pérdida de validación no mejora durante un número determinado de épocas, la tasa de aprendizaje se reduce automáticamente, permitiendo iniciar con pasos amplios y afinar progresivamente sin intervención manual. Se implementó un mecanismo de checkpoint que preserva el estado del modelo de la mejor época según el F1-score de validación, junto con el historial completo de métricas por época, garantizando reproducibilidad total sin necesidad de reentrenamiento.

B. Resultados en FER2013

El modelo alcanzó una accuracy de validación del 76.11% y un F1-score macro de 0.68 sobre el conjunto de validación de FER2013 (3.068 muestras). La Tabla I detalla las métricas por clase. *Alegría* obtuvo el mejor desempeño con un F1 de 0.88, consistente con su amplia representación en el dataset (1.185 muestras) y la alta distinción visual de su expresión. *Disgusto* y *miedo* presentan los valores más bajos (F1 de 0.46 y 0.55 respectivamente), lo cual es atribuible tanto a su menor representación como a la similitud morfológica con otras categorías.

Clase	Precisión	Recall	F1-score	Soporte
Alegría	0.93	0.83	0.88	1185
Seriedad	0.71	0.75	0.73	680
Tristeza	0.72	0.66	0.69	478
Sorpresa	0.72	0.82	0.77	329
Enojo	0.65	0.78	0.71	162
Disgusto	0.45	0.47	0.46	160
Miedo	0.45	0.69	0.55	74
Macro avg	0.66	0.72	0.68	3058
Weighted ave	0.78	0.76	0.77	3068

1. Tabla I — Reporte de clasificación CNN en FER2013 (validación)

C. Validación Cruzada en CK+

Para evaluar la capacidad de generalización del modelo, ambas arquitecturas —la CNN propia y el Vision Transformer de Hugging Face— fueron evaluadas sobre el dataset CK+ (618 muestras), que no formó parte del entrenamiento. La Tabla II compara los resultados.

Clase	CNN F1	ViT F1
Alegría	0.87	0.88
Seriedad	0.78	0.90
Tristeza	0.37	0.36
Sorpresa	0.77	0.92
Enojo	0.24	0.44
Disgusto	0.35	0.76
Miedo	0.51	0.18
Accuracy	65.5%	79.3%
Macro F1	0.56	0.64

2. Tabla II — Comparación CNN vs. ViT en CK+ (validación cruzada)

D. Análisis Comparativo

Los resultados sobre CK+ revelan un patrón diferencial claro entre ambas arquitecturas. El ViT supera a la CNN en cinco de las siete clases, con una mejora de 13.8 puntos porcentuales en accuracy global (79.3% vs. 65.5%) y 8 puntos en F1 macro (0.64 vs. 0.56). Las ganancias más significativas se concentran en *disgusto* (+41 pp en F1), *sorpresa* (+15 pp) y *seriedad* (+12 pp), lo que sugiere que el mecanismo de auto-atención del ViT captura con mayor eficacia las configuraciones musculares distribuidas que caracterizan estas emociones.

Sin embargo, dos clases escapan a esta tendencia. En *tristeza*, ambos modelos obtienen un F1 prácticamente idéntico (0.37 vs. 0.36), señalando una dificultad estructural que trasciende la arquitectura: la tristeza es una emoción de baja intensidad visual, fácilmente confundible con neutralidad. En *miedo*, la CNN supera al ViT con un F1 de 0.51 frente a 0.18 — la mayor diferencia a favor de la CNN en todo el estudio. Esta anomalía es atribuible a la escasísima representación de *miedo* en CK+ (25 muestras), que penaliza al ViT por su mayor sensibilidad al volumen de datos.

Es importante contextualizar que la comparación no se realiza en igualdad estricta de condiciones: el ViT opera sobre imágenes de 224×224 píxeles en RGB (22 veces más píxeles y tres veces más canales de entrada que los 48×48 en escala de grises de la CNN) y fue preentrenado sobre ImageNet-21k antes de su ajuste fino para emociones. La CNN, en cambio, fue diseñada y entrenada desde cero exclusivamente sobre FER2013. Que una arquitectura liviana y entrenada con recursos limitados alcance el 65.5% sobre un dataset externo no visto —y supere al ViT en una clase— constituye un resultado alentador.

V. Análisis de Sentimiento en Video

A. Pipeline de Procesamiento

La primera extensión del clasificador al dominio del video tiene como objetivo obtener una distribución emocional global representativa de la totalidad del contenido. Dado un archivo de video, se extraen fotogramas a una tasa fija de 1 FPS mediante OpenCV. Cada fotograma es procesado de forma secuencial: detección de rostro, recorte, preprocesamiento y clasificación. Al finalizar el video, las predicciones individuales de todos los frames son agregadas para producir una distribución emocional promedio expresada como porcentaje por clase.

B. Detección de Rostros con Haar Cascade

La localización de rostros se realiza mediante el clasificador Haar Cascade incluido en OpenCV, un método clásico basado en características de Haar y clasificadores en cascada de tipo AdaBoost. Sobre el bounding box detectado se aplican dos ajustes empíricos: un factor de reducción (*shrink_ratio* = 0.80) que contrae el recuadro para eliminar

regiones de fondo, y un desplazamiento vertical hacia abajo (*shift_ratio* = 0.10) que centra mejor el recorte sobre la región de expresión facial. El recorte resultante es convertido a escala de grises, redimensionado a 48×48 píxeles y normalizado con los mismos parámetros usados durante el entrenamiento.

C. Limitaciones

Si bien este enfoque produce una síntesis útil del contenido emocional de un video, presenta una limitación estructural: al colapsar toda la información temporal en un único vector promedio, se pierde la dinámica emocional del sujeto. Dos videos con distribuciones promedio idénticas pueden diferir radicalmente en su evolución — uno puede mostrar una emoción estable mientras que el otro alterna entre estados que se cancelan en el promedio. Adicionalmente, Haar Cascade presenta una tasa de falsos negativos no despreciable ante variaciones de iluminación o poses laterales.

Ambas limitaciones —la pérdida de información temporal y la fragilidad del detector— motivaron directamente la extensión desarrollada en la sección siguiente.

VI. Análisis Temporal de Emociones

A. Motivación

El objetivo de esta sección es evolucionar del análisis estático (un porcentaje promedio por video) hacia un sistema capaz de rastrear la emoción de un sujeto cuadro a cuadro, construyendo lo que denominamos una *curva de temperatura emocional*. Esta representación temporal permite identificar momentos específicos de cambio emocional, picos de intensidad, y transiciones entre estados afectivos — información que el promedio global destruye por definición.

B. Detección con YOLOv8

Para la etapa temporal se reemplazó Haar Cascade por el modelo YOLOv8 (*yolov8n-face.pt*), preentrenado específicamente para detección de rostros y disponible en Hugging Face. YOLOv8 ofrece mayor precisión, menor tasa de falsos positivos y mayor robustez ante variaciones de pose e iluminación. La CNN de clasificación de emociones no fue modificada: YOLOv8 actúa únicamente como detector de región de interés (ROI), entregando recortes de mayor calidad al clasificador.

C. Extracción Temporal

Para cada frame analizado (a una tasa configurable de 1 FPS), el sistema genera un registro con tres campos: el timestamp en segundos, la emoción dominante (argmax del vector de salida), y el vector completo de probabilidades para las siete clases. La acumulación de estos registros a lo largo del video produce una serie temporal de vectores de probabilidad que constituye la materia prima del análisis.

D. Suavizado por Rolling Average

Las predicciones frame-a-frame presentan ruido inherente: variaciones de iluminación, micro-expresiones transitorias o frames con detección imperfecta pueden producir oscilaciones que no reflejan cambios emocionales genuinos. Para atenuar este efecto se aplica un promedio móvil centrado de ventana $w = 5$ sobre los vectores de probabilidad. La emoción dominante suavizada se determina como el argmax del vector promediado, produciendo una secuencia temporal significativamente más coherente que la clasificación cruda frame-a-frame.

E. Visualización: Temperatura Emocional

El resultado es presentado mediante una figura de cuatro paneles complementarios: (1) un *stacked area chart* que muestra la distribución de probabilidades emocionales acumulada a lo largo del tiempo, permitiendo visualizar cómo cambia el peso relativo de cada emoción; (2) un *scatter plot* de la emoción dominante por instante, con y sin suavizado, que permite identificar transiciones puntuales; (3) una curva de confianza del modelo (probabilidad máxima por frame), que indica cuán seguro está el clasificador en cada instante; y (4) una curva de entropía de la distribución de probabilidades, que funciona como medida de ambigüedad emocional — valores altos de entropía indican momentos donde el modelo no puede discriminar claramente entre múltiples emociones.

VII. Conclusiones y Trabajo Futuro

Se desarrolló exitosamente un sistema integral de reconocimiento de emociones faciales que abarca desde el entrenamiento de una CNN propia hasta el análisis temporal en video. El modelo alcanzó una accuracy del 76.11% sobre FER2013 y demostró capacidad de generalización sobre el dataset externo CK+, donde obtuvo un 65.5% sin ajuste adicional. La comparación con un Vision Transformer preentrenado reveló que, si bien el ViT supera a la CNN en la mayoría de las clases (accuracy 79.3%), la CNN mantiene ventaja en *miedo* y opera con una fracción de los recursos computacionales y datos de preentrenamiento.

La extensión al dominio del video permitió construir curvas de temperatura emocional que rastrean la dinámica afectiva cuadro a cuadro. La incorporación de YOLOv8 como detector de rostros superó ampliamente a Haar Cascade en robustez, y el suavizado por promedio móvil produjo representaciones temporales coherentes. El prototipo resultante procesa videos de entrada y genera reportes visuales de la evolución emocional a lo largo de la sesión.

Como líneas de trabajo futuro se proponen: (a) explorar arquitecturas más profundas o técnicas de transfer learning para mejorar las métricas en clases minoritarias; (b) incorporar análisis multi-rostro simultáneo para escenarios con múltiples participantes; (c) implementar procesamiento en tiempo real mediante captura de cámara web; y (d) integrar el sistema con plataformas de videollamada para habilitar aplicaciones prácticas en recursos humanos, ventas y educación online.

Reconocimiento

Los autores agradecen al Ing. Gerardo Volcamiza, docente de la materia Visión por Computadora II de la Universidad de Buenos Aires, por las orientaciones técnicas y el acompañamiento durante el desarrollo de este trabajo.

Referencias

[1] I. J. Goodfellow *et al.*, "Challenges in representation learning: A report on three machine learning contests," *Neural Networks*, vol. 64, pp. 59–63, 2015.

[2] P. Lucey *et al.*, "The Extended Cohn-Kanade Dataset (CK+): A complete dataset for action unit and emotion-specified expression," in *Proc. IEEE CVPR Workshops*, 2010, pp. 94–101.

[3] G. Jocher, J. Qiu, and A. Chaurasia, "Ultralytics YOLOv8," 2023. [Online]. Available: https://github.com/ultralytics/ultralytics

[4] A. Dosovitskiy *et al.*, "An image is worth 16x16 words: Transformers for image recognition at scale," in *Proc. ICLR*, 2021.

[5] P. Viola and M. Jones, "Rapid object detection using a boosted cascade of simple features," in *Proc. IEEE CVPR*, 2001.

[6] A. Paszke *et al.*, "PyTorch: An imperative style, high-performance deep learning library," in *Proc. NeurIPS*, 2019.